정보 이론과 Cross Entropy

정 보 이 론 으 로 이 해 하 는 오 차 와 수 정

김승환

정보 이론과 Cross Entropy

정보란 무엇일까

정보 이론에서 정보(Information)는 '놀람의 정도'
→ 얼마나 놀라운가(=예상에서 얼마나 벗어났는가)

예를 들면..

뉴스 A: 내일 아침, 비가 온다.

뉴스 B: 내일 아침, 외계인이 강남역에 착륙한다.

둘중에 어떤 것이 더 예상에서 벗어났을까.?

각 케이스의 확률을 구해보면..

정보 이론과 Cross Entropy

정보란 무엇일까

정보량의 수식 → I(x)=−logP(x) 이라고 할 수 있다.

여기서 왜 하필 −log 를 쓸까?

1. 곱셈 구조(확률)를 덧셈 구조로 바꾸기 위해 로그를 사용

2. 좀 더 직관적(희귀할수록 큼)으로 만들기 위해,

3. p(x) <= 1 이므로 logP(x) 의 부호는 - 라서.

→2번의 예시로 들자면...
동전 1의 확률 과 동전 2의 확률 둘다 안다면..

logP(x1) + logP(x2) = log(1 / 2) + log(1 / 4) 이라고 할때
이때 log(1 / 2) = 1이므로 1bit 라 할 수있음.
따라서 **I(x1) + I(x2) 는 log(1 / 8) 이라 할 수 있고 3bit 로 표현할 수 있음.**

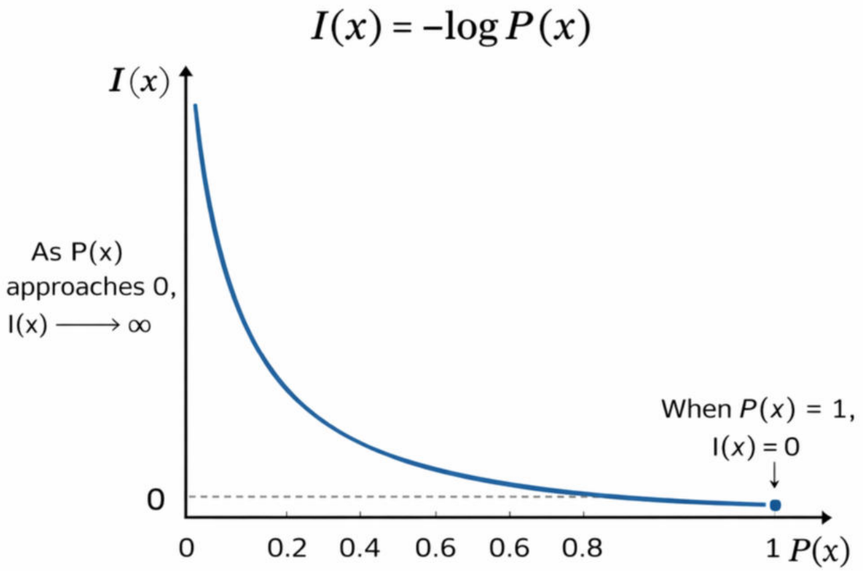

[정보 함수 그래프]

정보 이론과 Cross Entropy

Entropy : 불확실성의 기댓값

정보량에 확률을 곱해 모두 더한 기댓값.

= 평균 정보량'이 바로 엔트로피 H(P)라고 할수있음

$$H(P)=E[I(x)]=-\Sigma P(x)\log P(x)$$

A ●–	J ●–––	S ●●●
B –●●●	K –●–	T –
C –●–●	L ●–●●	U ●●–
D –●●	M ––	V ●●●–
E ●	N –●	W ●––
F ●●–●	O –––	X –●●–
G ––●	P ●––●	Y –●––
H ●●●●	Q ––●–	Z ––●●
I ●●	R ●–●	

예시로 들자면...

A, B, C, D 4개의 문자로만 언어를 이루는 세상에서..

각 알파벳을 신호로 표현한다면...

정보 이론과 Cross Entropy

Entropy : 불확실성의 기댓값

1 .무조건 2 bit 로 사용한다면 ...

A, B, C, D --〉 (00, 01, 10, 11) →→ 평균 2 Bit.

2 . 각 알파벳의 출연 빈도에 따른 정보량을 반영한다면...

A (확률 50%) → −log2(1/2) = 1 Bit → 부호: 0

B (확률 25%) → −log2(1/4) = 2 Bit → 부호: 10

C (확률 12.5%) → −log2(1/8) = 3 Bit → 부호: 110

D (확률 12.5%) → −log2(1/8) = 3 Bit → 부호: 111

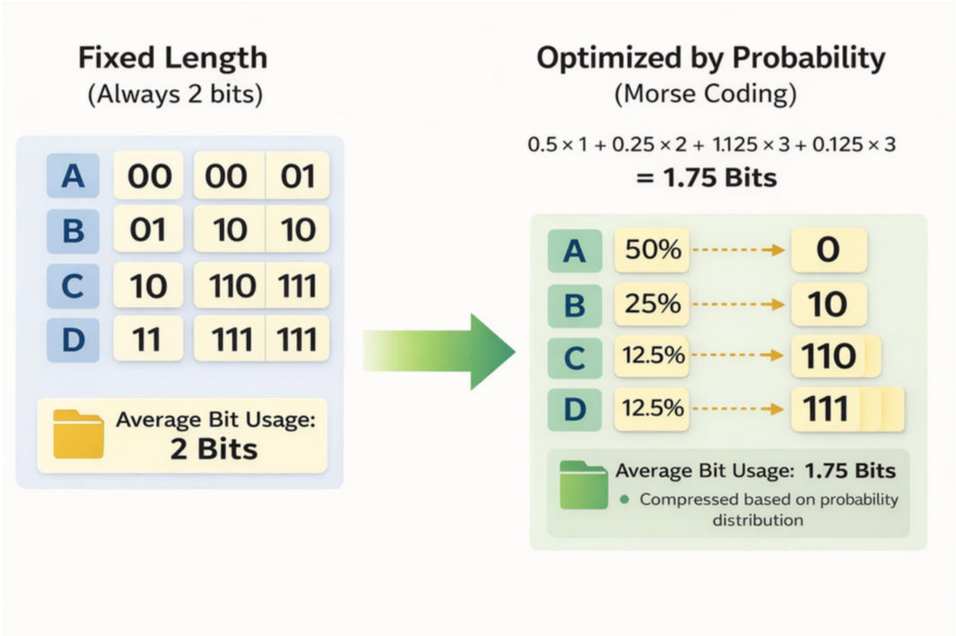

→ 확률을 활용해서 표현 비용을 줄임. 이것을 기반으로 효율적인 통신이 가능...

정보 이론과 Cross Entropy

Cross-Entropy

cross-entropy 의 수식은 **$H(P,Q) = -\Sigma P(x)\log Q(x)$**

현실(P)과 나의 예측 모델(Q)이 엇갈렸을 때.. 발생하는 총비용

또한 수식을 아래와 같이 쪼개볼 수 있음.

$$H(P,Q)=H(P)+D_{KL}(P \mid\mid Q)$$

여기서 중요한 KL Divergence 가 나옴..

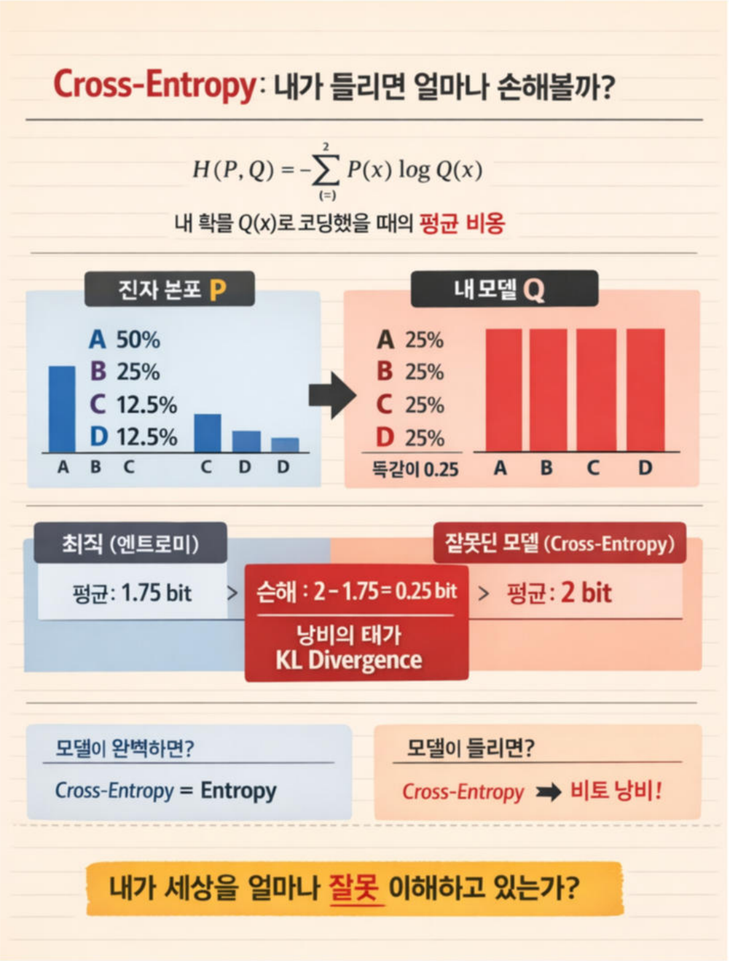

정보 이론과 Cross Entropy

KL Divergence

H(P,Q) = H(P) + DKL(P | | Q)

원 데이터의 엔트로피 분포의 차이

$$D_{KL}(P||Q) = \sum P(x) \log \frac{P(x)}{Q(x)}$$

$$D_{KL}(P||Q) = H(P,Q) - H(P)$$

H(P): 최적 (이론적 최소 비용)

H(P,Q): 내가 틀린 모델로 쓴 비용

이 차이가 낭비된 정보 비용이라고 할수있음.

→ **그래서 모든 모델은 KL 을 줄이는 것이 목표**

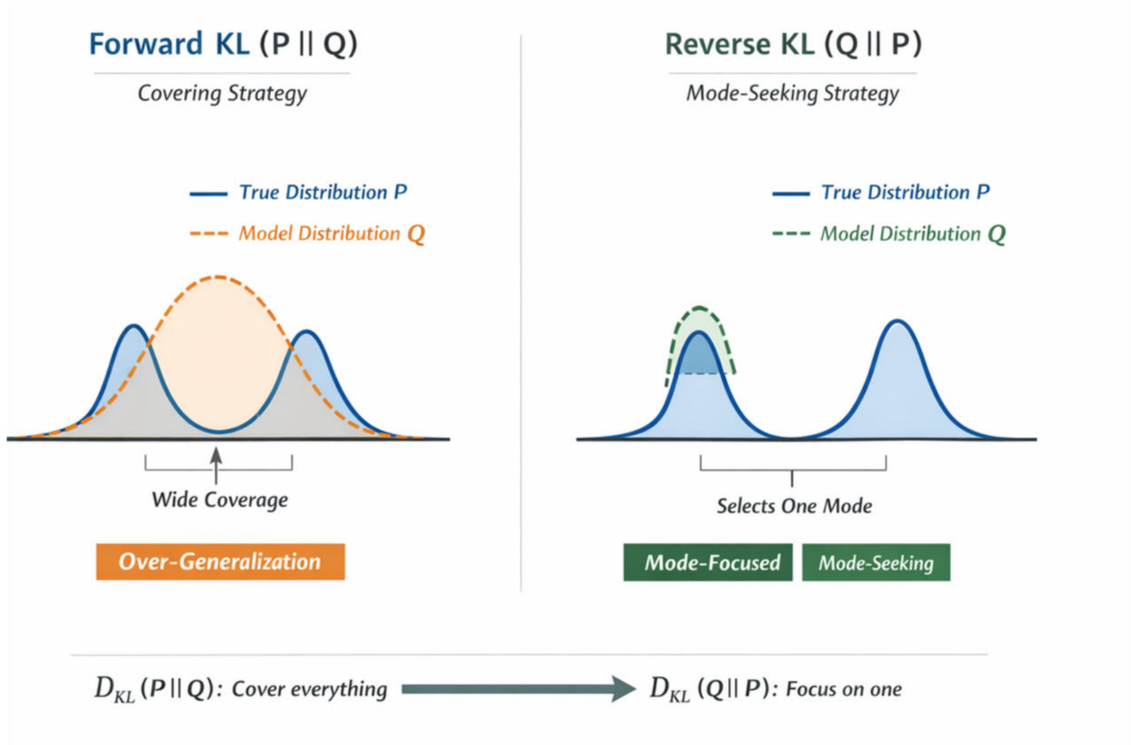

Forward KL과 Reverse KL 의 차이

정보 이론과 Cross Entropy

MSE vs Cross-Entropy

문제 1. 비 직관적

MSE (Mean Square Error)

정답(0, 1) 과 얼마나 가까운지를...

예를 들면
정답: 1, 예측 A: 0.9, 예측 B: 0.6 이라면

$(1- 0.9)^2 = 0.01$

$(1 - 0.6)^2 = 0.14$

차이는 보이지만.. 비교적 크지않음.

Cross-Entropy

기존 정보와 얼마나 차이가 나는지를..

→ 맞을 확률이 얼마나 되는지

0.9 → 거의 맞음 ..loss 작음

0.6 → 좀 틀림 ..loss 큼

정답과 예측값의 차이가 직관적

정보 이론과 Cross Entropy

MSE vs Cross-Entropy

문제 2. gradient가 망가짐

MSE (Mean Square Error)

$$(\hat{y} - y) \cdot \hat{y}(1 - \hat{y})$$

y_hat (1 - y_hat) 이 붙음.
y_hat가 0 또는 1에 가까이 도달하면.. 0으로 도달..

정답이 1, 예측이 0에 가까운 값이 나온다면..틀렷으나..
gradient가 0으로 값수정이 일어나지 않음.

Cross-Entropy

$$\frac{\partial L}{\partial z} = \hat{y} - y$$

깔끔하고 선형적
틀리면 바로 강하게 업데이트

정보 이론과 Cross Entropy

정보이론과 통계학

베르누이 분포의 우도인 Likelihood

$$P(Y \mid X)=a^{y}\,(1-a)^{(1-y)}$$

여기에 −log 를 씌우면

$$-\log P(Y \mid X)=-[y\log a+(1-y)\log(1-a)]$$

→ **Cross Entropy 와 같음.**

따라서 정보의 손실(CE)을 최소화 하는 것은
데이터가 나올 확률(MLE)을 극대화 한다고
세운 수식과 완전히 같음

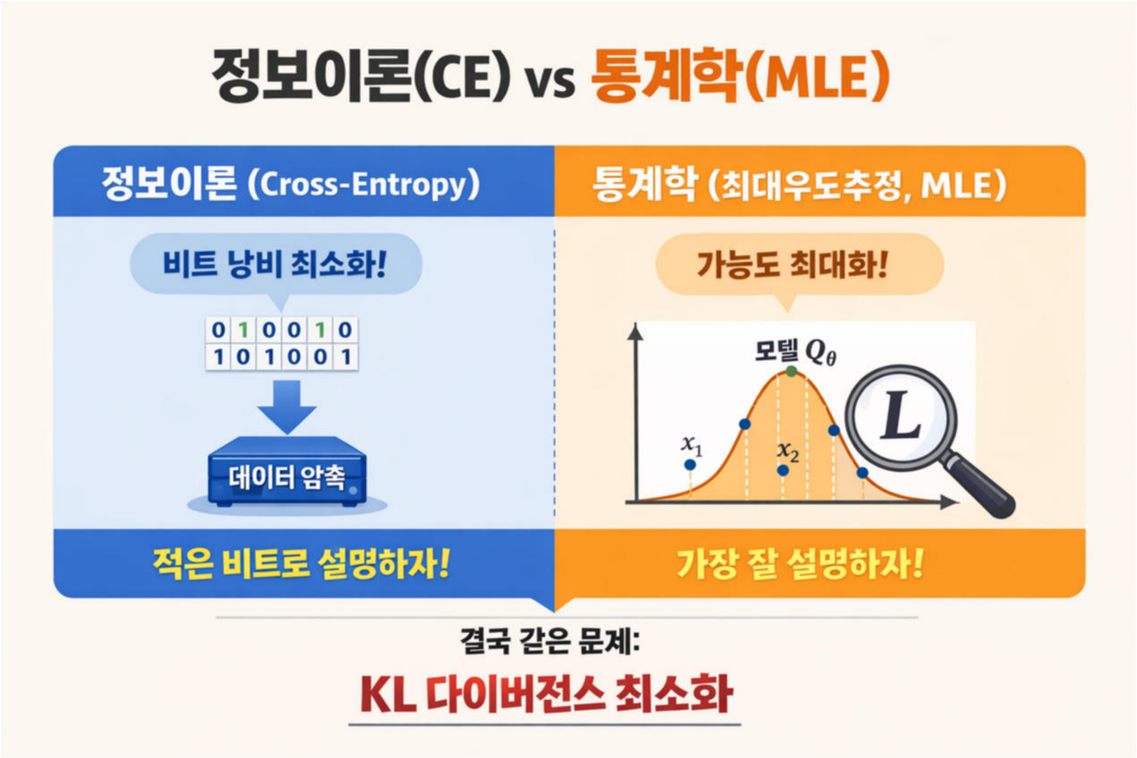

정보 이론과 Cross Entropy

그렇다면 우리는 어떤 학습을 하고 있는가?

나의 정답(Q)과 현실(P)은 다르다.

우리의 고통(Loss)은 세상이 틀렸기 때문이 아니라 현실(P)에 내 예상(Q)을 억지로 끼워 맞출 때(Cross) 발생.

확신을 버리고 현실과 내 사고의 간극을 인정하기.

성장은 나(Weight)를 바꾸는 역전파.

훌륭한 모델은 정답(현실)을 바꾸지 않음.
↓
오차를 정직하게 대면하고
(Loss 계산)
↓
나의 편견과 가중치를 수정한다
(역전파 업데이트)

뼈아픈 실패가 가장 가파른 도약.

자신이 완전히 틀렸음을 깨달았을 때, 역설적으로 기울기(Gradient)는 가장 커진다. 변명(기울기 소실)하며 학습을 멈추지 말고 오차를 100% 반영하여 자신의 사고를 최적화하자.

E. O. D