몬티 홀에서 트랜스포머까지

베이지안 사고방식으로 이해하는 확률과 AI

김승환

몬티 홀에서 트랜스포머까지

몬티홀 문제

3개의 문, 하나는 자동차, 둘은 염소가 들어있다.

이때 참가자가 문 하나를 선택

그러나 모든 정보를 알고 있는 사회자가 나머지 문 중

염소가 있는 문을 개방 후 질문을 하는데...

"선택을 바꾸시겠습니까?"

어차피 남은 문은 2개니 확률은 50:50이 아닐까...?

그러나.. 수학적 정답은 '무조건 바꿔야 한다'

몬티 홀에서 트랜스포머까지

직관의 오류

남은 문이 두 개이므로 50:50이라는 착각.

그러나 사회자는 무작위가 아닌 의도적으로

차가 없는 문을 열었음.

선택하지 않은 영역(B+C)에 있던 2/3의 확률이,

B가 탈락하며 C로 확률 전이.

→ **새로운 사후 정보가 기존의 확률 분포를 재구성**

새로운 정보를 반영하여 기존의 확률을 수정하는 것,
이것이 바로 사후 정보의 개념. 그리고 **베이즈 통계**의 핵심

몬티 홀에서 트랜스포머까지

베이즈 통계란

$$P(\theta \mid D) = \frac{P(D \mid \theta)P(\theta)}{P(D)}$$

Prior P(θ): 데이터 관측 전 초기 확률.

Likelihood P(D | θ): 가설이 맞을 때 데이터가 관측 될 가능성.

Evidence P(D): 관측 데이터를 정규화하는 marginal Likelihood.

Posterior P(θ | D): 데이터를 보고 난 후 업데이트된 확률.

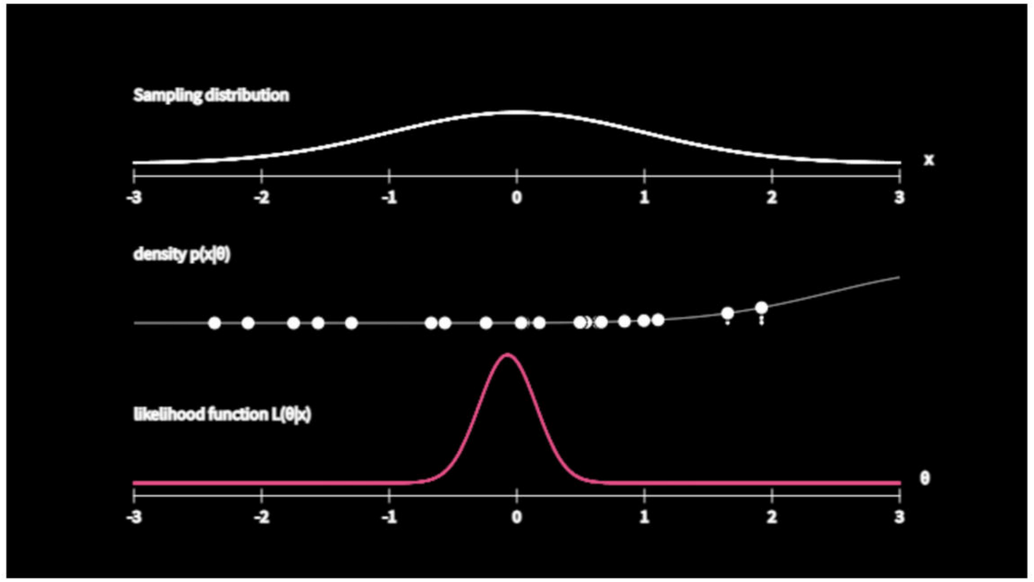

전통적 통계(빈도주의) 와는 다르게 고정된 정답을 찾는 것이 아니라
증거가 쌓일수록 정답에 가까워지는 과정..

몬티 홀에서 트랜스포머까지

Monte carlo

베이즈에서 중요한건 P(D) (Evidence) 를 찾는것.

그러나 $P(D)=\int P(D \mid \theta)P(\theta)d\theta$ 를 현실 세계에서 찾는 것은 불가능..

어떤 사건이 일어날 모든 경우의 수
(모든 파라미터 공간)에 대한 확률의 합

예를 들어 파라미터 100개, 딥러닝 weight 수백만 개인 경우.... 할수있을까..?

따라서 적분 대신 **랜덤 샘플 평균**을 사용함.
prob(a) = likelihood(a) x prior(a) 만으로도 가능..

따라서 무수히 많은 시행을 통해 통계적 수치를 추정할수 있음.

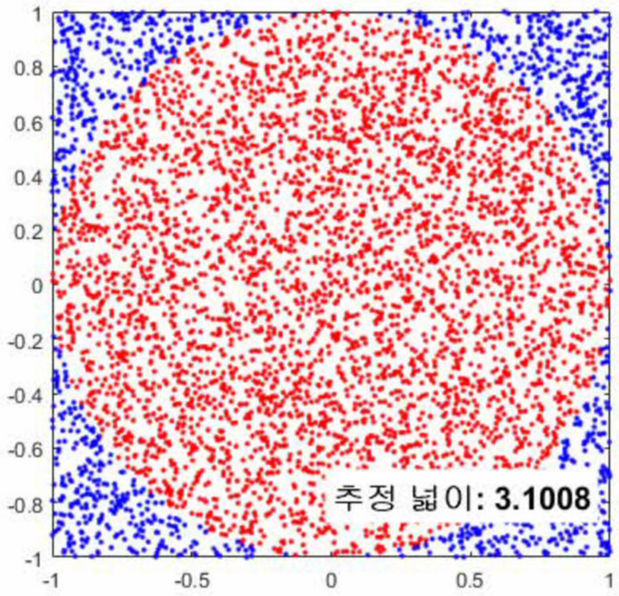

Monte Carlo 방식의 시뮬레이션 중 가장 유명한 것 중
하나인 원의 넓이를 계산하는 시뮬레이션
단순히 중심으로 부터 거리가 1 이내이면 빨간 색 원.
반례는 파란색으로 색칠 후 집계.
적분으로 원의 넓이를 구하는 것 보다
점의 숫자의 비율을 구해 넓이를 구하는게 쉬움....

몬티 홀에서 트랜스포머까지

Markov chain

어떤 상태에서 다른 상태로 넘어갈 때
바로 전 단계의 상태에만 영향을 받는 확률 과정을 의미

$$P(X_{t+1} \mid X_t)$$

예시로 다음 날의 점심은 **이전 날의 점심**에만 영향을 받음.
어제 한식을 먹었다면..
오늘 한식을 먹을 확률 (0.1) / 양식을 먹을 확률 (0.5) / 일식을 먹을 확률 (0.4)

따라서 전이 확률을 계산한다면. →

	한식	**양식**	**일식**
한식	0.1	0.5	0.4
양식	...	...	...
일식	...	...	...

몬티 홀에서 트랜스포머까지

MCMC: Markov Chain Monte carlo

무수히 많은 시도 + 전이 확률로 다음 샘플링 추천을 통해
분포를 추정 하는 방법.

다양한 분포 추정 알고리즘 중 Metropolis-Hastings을 설명하면...

현재 위치가 x, 다음 위치가 x` 라고 하면,
다음 위치 x` 의 수락 확률은 $\alpha - \min\left(1, \frac{P(x')}{P(x)}\right)$ 라고 할 수 있음

그러므로 확률이 높은 경우는 대부분 이동하고..
낮은 경우는 드물게 이동하며 샘플링이 이루어짐..

https://chi-feng.github.io/mcmc-demo/app.html?algorithm=HamiltonianMC&target=banana

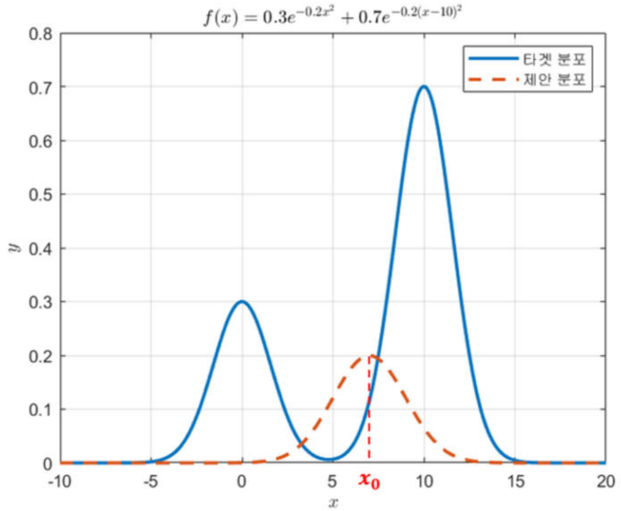

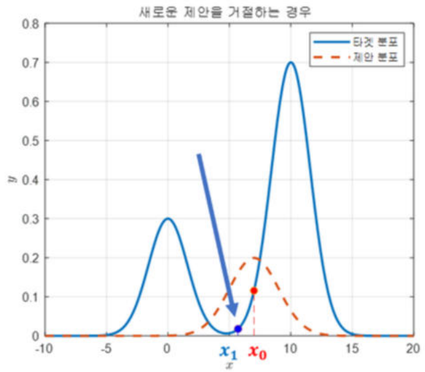

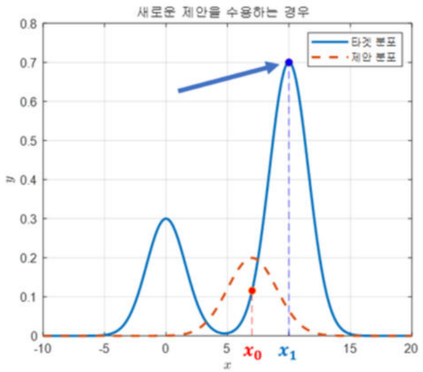

몬티 홀에서 트랜스포머까지

Attention: 정보의 확률적 선택

Transformer는 문장을 읽을 때

현재의 query(Q)를 문장 안의 key(K)들을 보고 유효도(V)를 계산함.

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d}})V$$

Transformer의 핵심 수식

The animal didn't cross the street because it was too tired

이 문장에서 it 이 가능한 후보는 animal 과 street.

Attention은 이 두 후보에 확률적인 가중치를 줌.

animal : 0.8, street : 0.2. 이렇게..

LLM이 문장을 읽는 과정

prior context → new token → update

몬티 홀에서 트랜스포머까지

Bayesian Thinking

베이지안 사고의 핵심은 세 단계.

Prior → Evidence → Posterior
(가설) (데이터) (업데이트)

그러나 우리는 보통 이렇게 살지 않음.

대부분 사람들은 의견 → 고집 → 끝. 의 순서

몬티 홀에서 트랜스포머까지

Bayesian Thinking

그러면 우리는 베이지안으로 살아가야 하지 않을까...?

베이지안 사고의 핵심은 믿음은 고정된 것이 아니라 업데이트되는 것..

1. 내가 틀릴 수 있다.

항상 사전 확률(Prior)을 열어 두는 것.
확신보다 가설로 생각하기.

2. 커리어도 베이지안 업데이트와 같다.

가설 (내가 잘할 것 같은 분야)
↓
데이터 (성과, 시장 반응, 피드백)
↓
업데이트 (다음 커리어 선택)

3. 미래는 기본적으로 불확실하다.

완벽한 계획은 거의 항상 틀린다.
그래서 중요한 것은 계획의 정확도보다
업데이트를 얼마나 빠르게 하는지..

E. O. D