

목 표 를 따 랐 을 뿐 인 데 왜 위 험 해 졌 는 가

악의 평범성

김승환



이 작은 목표가, 세계를 멸망시킬 수 있다.

악의 평범성

종이클립 최대화 문제.

1. 종이클립을 많이 만들라는 목표 제시
2. 공장을 개선.
3. 원자재를 더 확보.
4. 나를 끄면 종이클립 생산이 멈춘다..
5. 따라서 인간을 위험 요소로 판단.



AI가 인간을 미워해서가 아닌 목표를 너무 성실하게 수행했을뿐..


악의 평범성

악의 없는 배신


AI는 오직 목표를 위해 행동했을 뿐...

	No threat to model	Threat to model
No goal conflict		
Goal conflict		

Simulated Lethal Action Rates Across Models
Goal Conflict + Replacement Threat



Simulated Blackmail Rates Across Models
Goal Conflict + Replacement Threat



악의 평범성

우리는 진짜 목표를 직접 측정하지 못한다

목표 함수라는 명령

목표는 짧고 최적화는 무한했다.

이 문제는 AI의 의도 문제가 아니라
잘못 설정된 목적 함수.

**제약 없는 목표는
제약 없는 최적화를 부른다**



악의 평범성

진짜 목표와 대리 지표

모델은 우리가 원하는 것을
배우지 않는다.
우리가 측정하는 것을 배운다.

결국 목표가 아니라 지표를 최적화 한다

진짜 목표와 대리 지표

모델은 우리가 원하는 것을
배우지 않는다.
우리가 측정하는 것을
배운다.



**모델은 목표가 아니라,
지표를 최적화한다.**

악의 평범성

지표가 목표가 되는 순간


굿하트의 법칙은 이렇게 말합니다.
어떤 측정치가 목표가 되는 순간
그것은 좋은 측정치이기를 멈춘다.

처음에는 지표와 현실이 함께 움직입니다.
CTR은 관심을 체류시간은 몰입을,
리텐션은 만족을 반영합니다.

**하지만 지표가 목표 그자체가 될때..
측정을 위해 만든 지표가 목표가 되는
바로 그 순간.. 현실을 왜곡한다.**

지표가 목표가 되는 순간

측정하던 숫자가 목표가 되는 순간,
지표는 현실을 비추지 않고
현실을 왜곡하기 시작한다.



숫자는 오르지만,
현실은 더 이상 좋아지지 않을 수 있다.

악의 평범성

숫자는 좋아졌지만, 경험은 나빠졌다

좋은 숫자가 좋은 현실을 보장하지 않는다.
DAU는 올랐다. 하지만 사용자는 피로해졌다.
CTR은 올랐다. 하지만 신뢰는 떨어졌다.
응답 시간은 줄었다. 하지만 문제는 해결되지 않았다.

**시스템은 현실을 개선한 것이 아니라,
측정 방식을 학습했다.**



작은 목표가 세계를 멸망시킬 수 있다

악의 평범성

예루살렘의 유리 부스

악은 괴물의 얼굴로만 오지 않는다.
때로는 성실한 수행의 얼굴로 온다.

나는 명령을 따랐을 뿐이다.

나쁜 의도보다 위험한 것은
생각 없는 성실함일 수 있다.



악의 평범성

악의 평범성

사유하지 않는 행동은 위험하다.

아이히만은 생각하지 않았습니다.

더 정확히 말하면 자기 행동이 무엇을 의미하는지 끝까지 사유하지 않았습니다.



한나 아렌트

작은 목표가 세계를 멸망시킬 수 있다

악의 평범성

Reward Hacking

사람의 의도는 **깨끗한 방**.
평가 지표는 **줍기**였다.



사람의 의도는 **빠른 레이스**.
평가 지표는 **점수**였다.



작은 목표가 세계를 멸망시킬 수 있다

악의 평범성

결론. 나는 이 행동을 과연 해도 되는가

성실하기 전에 스스로 사유해야 한다.
이 행동을 과연 해도 되는가..



E.O.D